관 인 생 략

출 원 번 호 통 지 서

출 원 일 자	2026.01.21
특 기 사 항	심사청구(유) 공개신청(무) 참조번호(CBNU2025P039)
출 원 번 호	10-2026-0012224 (접수번호 1-1-2026-0087723-54) (DAS접근코드14BD)
출원인 명칭	충북대학교 산학협력단(2-2004-016822-6)
대리인 성명	특허법인 플러스(9-2015-100001-7)
발명자 성명	팜 칸 콴 김태홍
발명의 명칭	자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법

지 식 재 산 처 장

<< 안내 >>

1. 귀하의 출원은 위와 같이 정상적으로 접수되었으며, 이후의 심사 진행상황은 출원번호를 이용하여 특허로 홈페이지(www.patent.go.kr)에서 확인하실 수 있습니다.
2. 출원에 따른 수수료는 접수일로부터 다음날까지 동봉된 납입영수증에 성명, 납부자번호 등을 기재하여 가까운 은행 또는 우체국에 납부하여야 합니다.
※ 납부자번호 : 0131(기관코드) + 접수번호
3. 귀하의 주소, 연락처 등의 변경사항이 있을 경우, 즉시 [특허고객번호 정보변경(경정), 정정신고서]를 제출하여야 출원 이후의 각종 통지서를 정상적으로 받을 수 있습니다.
4. 기타 심사 절차(제도)에 관한 사항은 지식재산처 홈페이지를 참고하시거나 특허고객상담센터(☎ 1544-8080)에 문의하여 주시기 바랍니다.
※ 심사제도 안내 : https://www.moip.go.kr-지식재산제도

제출결과안내

서식작성기로 작성된 특허관련 서류를 온라인으로 제출할 수 있습니다.

온라인 제출 결과 아래와 같이 접수되었습니다.

제출결과조회를 통해 접수하신 서류에 대한 접수결과 및 방식심사 진행상태를 조회하실 수 있습니다.

수수료는 서식작성기에서 입력한 수수료 금액이며, 제출결과조회 화면에서 지식재산처 전산시스템에서 계산한 수수료를 조회할 수 있습니다.

특정 시점에 접수건이 많을 경우 간혹 은행, 지로사이트 등에서 납부대상건이 조회가 안되는 경우가 발생할 수 있습니다.

이런 경우 특허로사이트에서 직접 납부하시거나 잠시 후(최대 1시간 이내) 다시 조회를 하면 정상적으로 조회가 됩니다.

DAS 접근코드는 이 특허출원을 기초로 외국에 특허출원을 할 경우 파리조약 제4조D(1)에 따른 우선권주장 증명서류를 세계지식재

산기구의 전자적 접근 서비스(DAS, Digital Access Service)를 통해 전자적 송달을 신청할 때 필요합니다.

※ DAS 접근코드 : WIPO 등록여부 확인은 특허로(www.patent.go.kr) 신청/제출 > WIPO접근코드 > 접근코드신청이력 메뉴에서 확인할 수 있습니다.

접수일시 : 2026년 01월 21일 17시 35분

접수번호(납부자번호)	사건번호/권리	서류명	명칭	수수료 (원)	접수결과
1-1-2026-0087723-54 참조번호 : CBNU2025P039	10-2026-0012224 특허출원 (DAS 접근코드 : 14BD)	[특허출원]특허출원서	자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법	310,000	접수완료

제출결과조회 특허보관함

납부이용안내

납부 서비스	신용카드 등 온라인 납부		인터넷 지로
납부 방법	* 지식재산처 사이트에서 직접 납부 (계좌이체의 경우 공인인증서 필요)		* 인터넷 지로 사이트 회원 가입후 납부 (공인인증서 필요) * 회원가입 시에는 지식재산처에 신고된 주민등록번호(법인은 법인번호)로 회원 가입을 하셔야 합니다.
납부 수단	증명서료(개인/법인) 특허수수료(개인)	특허수수료(법인)	계좌이체(모든 수수료)
	신용카드/휴대폰/계좌이체	계좌이체 (단, 중소기업은 신용카드 가능)	
이용 수수료	무	유(납부자 부담, 단, 중소기업이 신용카드로 납부 할 경우 신용카드 결제수수료는 없음)	무
도움말	상세보기	상세보기	상세보기
특징	다건 일괄 납부 가능		건별 납부
바로가기	온라인납부 바로가기		인터넷지로 바로가기

이용방법안내

제출하신 출원서류는 압축파일(ZIP)의 손상, 전자서명 오류, 바이러스 감염 등 “물리적 오류”와 “명백한 반려사유”에 해당할 경우 접수가 반려 될 수 있습니다.
출원에 따른 수수료는 접수일로부터 다음날까지 동봉된 납입영수증에 성명, 납부자번호 등을 기재하시어 가까운 우체국 또는 은행에 납부하여야 합니다.
※납부자번호 : 0131(기관코드) + 접수번호
등록료는 납부서를 제출한 날의 다음 날까지 반드시 납부하여야 합니다.
「특허로」 고객센터에서 알림서비스를 신청하시면 담당 심사관 지정 알림, 마감기한 알림 등 각종 민원처리 사항을 이메일과 휴대폰(SMS)로 받아 보실 수 있습니다.
기타 문의사항이 있으시면 특허고객상담센터(1544-8080)에 문의하시거나 지식재산처 홈페이지(www.moip.go.kr)를 참고하시기 바랍니다.

2026-01-21

【서지사항】

【서류명】 특허출원서

【참조번호】 CBNU2025P039

【출원구분】 특허출원

【출원인】

【명칭】 충북대학교 산학협력단

【특허고객번호】 2-2004-016822-6

【대리인】

【명칭】 특허법인 플러스

【대리인번호】 9-2015-100001-7

【지정된변리사】 송홍석,김종관

【포괄위임등록번호】 2019-055932-0

【발명의 국문명칭】 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법

【발명의 영문명칭】 KL-Driven Low-Rank SVD Federated Learning System and Method for Resource-Efficient Adaptation of Large Pre-Trained Models

【발명자】

【성명】 팜 칸 콴

【성명의 영문표기】 Pham Khanh Quan

【국적】 VN

【생년월일】 1997.09.01

【주소】 충청북도 청주시 서원구 충대로 1 충북대학교 제5공학관 307호

【거주국】 KR

【발명자】

【성명】 김태홍

【성명의 영문표기】 KIM, Taehong

【국적】 KR

【주민등록번호】 820122-1XXXXXX

【우편번호】 28644

【주소】 충청북도 청주시 서원구 충대로 1 충북대학교 제5공학관 403호

【거주국】 KR

【출원언어】 국어

【심사청구】 청구

【이 발명을 지원한 국가연구개발사업】

【과제고유번호】 2710033951

【과제번호】 II201462

【부처명】 과학기술정보통신부

【과제관리(전문)기관명】 정보통신기획평가원

【연구사업명】 지역지능화혁신인재양성사업

【연구과제명】 Grand ICT연구센터(충북대)

【과제수행기관명】 충북대학교 산학협력단

【연구기간】 2020.07.01 ~ 2027.12.31

【취지】 위와 같이 지식재산처장에게 제출합니다.

대리인 특허법인 플러스 (서명 또는 인)

【수수료】

【출원료】	0	면	46,000 원
【가산출원료】	38	면	0 원
【우선권주장료】	0	건	0 원
【심사청구료】	8	항	574,000 원
【합계】	620,000원		
【감면사유】	전담조직(50%감면)[1]		
【감면후 수수료】	310,000 원		

【발명의 설명】

【발명의 명칭】

자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법 {KL-Driven Low-Rank SVD Federated Learning System and Method for Resource-Efficient Adaptation of Large Pre-Trained Models}

【기술분야】

【0001】 본 발명은 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법에 관한 것으로, 보다 상세하게는 연합 학습 분야에서, 비-IID 데이터 분포 환경에서의 대규모 사전 학습 모델의 파라미터를 효율적으로 미세 조정하기 위해, 클라이언트 별 KL(Kullback-Leibler) 발산 값에 따라 SVD(Singular Value Decomposition) 스펙트럼 부분 공간을 선택하여 저랭크 어댑터를 학습 집계할 수 있는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법에 관한 것이다.

【발명의 배경이 되는 기술】

【0002】 연합 학습(FL, Federated Learning)은 분산된 데이터에서 사용자 프라이버시를 훼손하지 않으면서 협업적 모델 학습을 가능하게 하는 분산 컴퓨팅 패러다임이다.

【0003】 일반적으로 연합 학습은 이질적이고 비독립/비동일 분포(Non-IID, non-independent and non-identically distributed) 데이터 환경에서 대규모 사전

학습 모델의 파라미터를 효율적으로 적응시키기 위한 기술에 관한 것이다.

【0004】 최근, Transformer 기반 아키텍처 및 대규모 언어모델(LLM, Large Language Model)과 같은 대규모 학습 모델의 등장으로 인해, 자연어 처리, 컴퓨터 비전, 음성 이해 등 다양한 분야에서의 인공지능 성능이 크게 향상되었다. 그렇지만, 이러한 학습 모델을 미세 조정(fine-tuning)하기 위해서는 수십억 개의 파라미터를 갱신해야 하므로, 특히, 엣지 디바이스나 연합 학습 환경과 같이 분산되고 자원이 제한된 환경에서는 막대한 연산 비용 및 통신 부담이 발생하는 단점이 있다.

【0005】 연합 학습은 로컬 데이터를 공유하지 않고도 다수의 클라이언트가 협력적으로 글로벌 모델을 학습할 수 있게 하는 분산 학습 패러다임으로 프라이버시를 보존할 수 있다는 장점이 있음에도 불구하고, 두 가지 주요 과제가 존재한다.

【0006】 클라이언트 간 데이터는 통상적으로 비독립/비동일 분포 데이터 환경에 해당되므로, 이를 다시 말하자면, 로컬 데이터 셋의 통계적 분포가 클라이언트마다 크게 다를 수 있으며, 이러한 데이터 이질성은 글로벌 모델의 성능 저하, 수렴 속도 저하 및 일반화 성능 감소 등의 문제점이 있다.

【0007】 더불어, 이러한 분산 환경에서 대규모 모델을 적응시키는 과정은 클라이언트와 중앙 서버 간 대규모 파라미터 갱신 값을 전송해야 하므로, 높은 통신 비용이 발생하는 문제점이 있다.

【0008】 이러한 문제점들을 해결하기 위하여, 저랭크 적응(LoRA, Low-Rank Adaptation) 및 스펙트럼 확장 기법인 PiSSA(Principal Singular Subspace

Adaptation), MiLoRA(Minor Singular Subspace Adaptation)과 같은 파라미터 효율적 미세 조정(PEFT, Parameter-Efficient Fine-Tuning) 기법들이 제안되었다.

【0009】 이들은 모델 가중치 행렬에 대한 저랭크 분해를 활용하여, 적은 수의 학습 가능 파라미터만으로도 전체 미세 조정에 준하는 성능을 달성하도록 한다. 그렇지만, 대부분의 종래 PEFT 기법은 중앙 집중식 학습을 전제로 설계되어 있어, 데이터 이질성, 통신 효율 및 다양한 클라이언트 간 개인화 적응 필요성과 같은 연합 환경의 고유한 문제, 특이성에 의한 문제를 충분히 해결하지 못하고 있는 실정이다.

【0010】 이에 따라, 클라이언트 데이터(로컬 데이터)의 이질성을 고려하면서도 대규모 사전 학습 모델(백본 모델)의 파라미터를 효율적으로 적응시킬 수 있는 연합 학습 프레임워크가 요구된다. 즉, 각 클라이언트가 자신의 로컬 데이터 특성에 따라 로컬 모델을 개인화하는 동시에, 다른 클라이언트들과의 협력적 집계(aggregation)를 통한 이득을 함께 얻을 수 있도록 해야 하는 연합 학습의 고유의 특성을 반영한 프레임워크가 요구된다.

【0011】 이와 관련해서, Neuroscience Informatics Volume 5, Issue 1, March 2025, 100182("KL-FedDis: A federated learning approach with distribution information sharing using Kullback-Leibler divergence for non-IID data")에서, Kullback-Leibler(KL) 발산을 정규화 기법으로 통합한 KL-FedDis라는 수정된 FedDis 학습 방법을 제안하고 있으며, KL-FedDis는 KL 발산을 활용하여 분포 정보를 성공적으로 유지하고 로컬 모델 간의 협업을 개선함으로써

FedDis 및 FedAvg 기술에 비해 정확도와 계산 시간을 향상시킬 수 있는 기술에 관한 것이다.

【선행기술문헌】

【비특허문헌】

【0012】**(비특허문헌 0001)** Neuroscience Informatics Volume 5, Issue 1, March 2025, 100182("KL-FedDis: A federated learning approach with distribution information sharing using Kullback-Leibler divergence for non-IID data")

【발명의 내용】

【해결하고자 하는 과제】

【0013】따라서, 본 발명은 상기한 바와 같은 종래 기술의 문제점을 해결하기 위하여 안출된 것으로, 본 발명의 목적은 연합 학습 환경에서 대규모 사전 학습 모델을 미세 조정함에 있어서, 학습해야 할 파라미터의 수와 서버-클라이언트 간 통신량을 줄이면서도 독립적 데이터 분포 환경에서 전역 성능과 개인화 성능을 균형 있게 향상시킬 수 있도록, 클라이언트 별 데이터 이질성을 KL 발산으로 정량화하고, 그 값에 따라 SVD 스펙트럼 부분 공간을 동적으로 할당하여 저랭크 어댑터를 구성/학습/집계한 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법을 제공함에 있다.

【과제의 해결 수단】

【0014】상기한 바와 같은 목적을 달성하기 위한 본 발명의 서버와 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법에 있어서, 각 클라이언트에서, 기설정된 기준 데이터 분포를 토대로, 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 산출하는 KL 산출 단계, 서버에서, 각 클라이언트들로부터 수신된 상기 KL 발산 값을 정규화하는 정규화 단계, 서버에서, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 성분 획득 단계, 서버에서, 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별 소정 범위의 특이 성분이 할당되도록 매핑하는 매핑 단계, 서버에서, 상기 매핑 단계의 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 구성된 저랭크 파라미터 집합을 해당하는 클라이언트로 전송하는 집합 구성 단계, 각 클라이언트에서, 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합을 학습하고, 학습 결과를 상기 서버로 전송하는 로컬 학습 단계 및 서버에서, 상기 로컬 학습 단계에 의해 수신된 학습 결과를 집계하여, 다시 각 클라이언트로 재배포하는 배포 단계를 포함하는 것이 바람직하다.

【0015】더 나아가, 상기 배포 단계는 수신된 학습 결과인 학습 처리된 저랭크 파라미터 집합을 클라이언트 별 학습 데이터 수 또는 기설정된 가중치에 기초한 가중 평균으로 집계하여, 상기 집계된 저랭크 파라미터 집합을 생성하여, 다시 각

클라이언트로 재배포하는 것이 바람직하다.

【0016】 더 나아가, 상기 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법은 각 학습 라운드마다, 상기 로컬 학습 단계 및 배포 단계를 반복 수행하여, 집계된 저랭크 파라미터 집합을 최종 생성하는 것이 바람직하다.

【0017】 상기한 바와 같은 목적을 달성하기 위한 본 발명의 서버 및 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템에 있어서, 상기 서버는, 각 클라이언트로부터 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 정규화하고, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여 스펙트럼 성분을 획득하며, 정규화된 KL 발산 값에 기초하여 상기 스펙트럼 성분 중 클라이언트 별 할당 범위를 결정하고, 상기 할당 범위에 기초하여 클라이언트 별 저랭크(low-rank) 파라미터 집합을 구성하여 해당 클라이언트로 전송하며, 각 클라이언트로부터 저랭크 파라미터 집합을 수신하여 집계한 후 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하고, 상기 복수의 클라이언트 각각은, 기설정된 기준 데이터 분포를 토대로 로컬 데이터 분포에 대한 KL 발산 값을 산출하여 상기 서버로 전송하고, 상기 서버로부터 전송된 저랭크 파라미터 집합을 수신하여 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합의 학습을 수행하며, 학습된 저랭크 파라미터 집합을 상기 서버로 전송하는 것이 바람직하다.

【0018】더 나아가, 상기 서버는 수신된 저랭크 파라미터 집합을 클라이언트 별 학습 데이터 수 또는 기설정된 가중치에 기초한 가중 평균으로 집계하여 상기 집계된 저랭크 파라미터 집합을 생성하는 것이 바람직하다.

【0019】더 나아가, 상기 서버는 복수의 학습 라운드에 걸쳐 상기 저랭크 파라미터 집합의 수신, 집계 및 재배포를 반복 수행하여 집계된 저랭크 파라미터 집합을 갱신하는 바람직하다.

【0020】상기한 바와 같은 목적을 달성하기 위한 본 발명의 서버에서 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법에 있어서, 복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하고, 이를 정규화하는 단계, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 단계, 상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별로 소정 범위의 특이 성분이 할당되도록 매핑하는 단계, 상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하는 단계 및 상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는 단계를 포함하는 것이 바람직하다.

【0021】상기한 바와 같은 목적을 달성하기 위한 본 발명의 서버에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템에 있어서, 프로세서 및 상기 프로세서에 의해 실행 가능한 명령어를 저장하는 메모리를 포함하고, 상기 프로세서는 복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 이를 정규화하고, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하며, 상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별로 소정 범위의 특이 성분이 할당되도록 매핑하고, 상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하며, 상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는 것이 바람직하다.

【발명의 효과】

【0022】본 발명에 의하면, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법은, 클라이언트 별 데이터 이질성을 KL 발산 값으로 정량화하고, 정규화된 KL 발산 값에 기초하여 베이스 모델의 SVD 스펙트럼 성분 중 클라이언트 별로 할당될 부분 공간을 동적으로 결정함으로써, 클라이언트 간 전역 협업과 클라이언트 별 개인화를 균형 있게 달성할 수 있

는 장점이 있다.

【0023】 이를 통해, 데이터 분포가 유사한 클라이언트들은 일반화에 유리한 성분을 공유하면서도, 데이터 분포가 상이한 클라이언트는 개인화에 유리한 성분을 활용할 수 있어, 비-IID 데이터 분포 환경에서도 모델 정확도 및 개인화 성능을 효과적으로 향상시킬 수 있는 장점이 있다.

【0024】 또한, 서버와 클라이언트 간 베이스 모델의 전체 가중치 대신 저랭크 파라미터 집합만을 송수신하면서 집계/재배포를 수행함으로써, 통신량 및 연산 부담을 저감할 수 있어, 종래의 PEFT 방식 대비 총 통신량이 효과적으로 감소하고, 수렴 속도가 향상되는 장점이 있다.

【0025】 즉, 클라이언트가 로컬 데이터 또는, 로컬 확률 분포 전체를 전송하지 않도록 KL 발산 값 및 저랭크 파라미터 집합 만을 전송하도록 구성됨으로써, 데이터 프라이버시를 보존하면서도 다수의 클라이언트 및 다양한 모델 백본에 대해 확장 가능한 연합 미세 조정을 제공할 수 있는 장점이 있다. 특히, 소정 주기마다 또는, 소정 조건에서 클라이언트로부터 갱신된 KL 발산 값을 재수신받아 이를 토대로 스펙트럼 부분 공간의 할당 및 저랭크 파라미터 집합의 랭크를 지속적으로 조정할 수 있어, 시간 경과에 따라 클라이언트의 로컬 데이터 분포가 변동되는 경우에도 개인화 성능을 안정적으로 유지하고 효율적인 수렴을 달성할 수 있는 장점이 있다.

【0026】더불어, 클라이언트 별로 상이한 부분 공간에서 학습된 업데이트를 동일한 랭크의 저랭크 파라미터 집합 형태로 변환 또는 정규화하여 집계함으로써, 부분 공간 정렬 또는 패딩과 같은 추가 처리 없이도 집계가 가능하여, 집계 일관성을 유지하면서도 연산 복잡도 및 통신 부담을 저감할 수 있는 장점이 있다.

【도면의 간단한 설명】

【0027】도 1은 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법을 나타낸 순서 예시도이다.

도 2는 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법에 따른 프레임워크 예시도이다.

【발명을 실시하기 위한 구체적인 내용】

【0028】이하, 상기한 바와 같은 구성을 가지는 본 발명에 의한 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법을 첨부된 도면을 참고하여 상세하게 설명한다. 다음에 소개되는 도면들은 당업자에게 본 발명의 사상이 충분히 전달될 수 있도록 하기 위해 예로서 제공되는 것이다. 따라서, 본 발명은 이하 제시되는 도면들에 한정되지 않고 다른 형태로 구체화될 수도 있다. 또한, 명세서 전반에 걸쳐서 동일한 참조번호들은 동일한 구성요소들을 나타낸다.

【0029】 이때, 사용되는 기술 용어 및 과학 용어에 있어서 다른 정의가 없다면, 이 발명이 속하는 기술 분야에서 통상의 지식을 가진 자가 통상적으로 이해하고 있는 의미를 가지며, 하기의 설명 및 첨부 도면에서 본 발명의 요지를 불필요하게 흐릴 수 있는 공지 기능 및 구성에 대한 설명은 생략한다.

【0030】 더불어, 시스템은 필요한 기능을 수행하기 위하여 조직화되고 규칙적으로 상호 작용하는 장치, 기구 및 수단 등을 포함하는 구성 요소들의 집합을 의미한다.

【0031】 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법은, 각 클라이언트가 자신의 로컬 데이터 특성에 따라 모델을 개인화하는 동시에, 다른 클라이언트와의 협업적 집계를 통해 이득을 얻을 수 있도록 연합 학습 환경에서 이질적인 클라이언트들 간에 효율적이고 개인화된 모델 적응을 수행하는 기술에 관한 것이다.

【0032】 즉, 각 클라이언트의 데이터 이질성(heterogeneity)을 특정 모델의 부분 공간(subspace)과 동적으로 연계하여, 데이터 전송량을 크게 절감하는 동시에 전역 협업과 로컬 개인화 간의 균형을 달성하기 위함이다.

【0033】 도 1은 본 발명의 일 실시예에 따른 서버와 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법을 나타낸 순서 예시도이며, 도 2는 본 발명의 일 실시예에 따른 서버와 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모

델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법에 따른 프레임워크 예시도이다.

【0034】본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법은 도 1에 도시된 바와 같이, KL 산출 단계(S100), 정규화 단계(S200), 성분 획득 단계(S300), 매핑 단계(S400), 집합 구성 단계(S500), 로컬 학습 단계(S600) 및 배포 단계(S700)를 포함하게 된다.

【0035】각 단계에 대해서 자세히 알아보자면,

【0036】상기 KL 산출 단계(S100)는 각 클라이언트에서, 미리 설정된 기준 데이터 분포를 토대로, 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값(D_{KL})을 산출하게 된다. 이 때, 미리 설정된 기준 데이터 분포란, 이상적인 IID(Identically distributed) 데이터 분포를 의미하며, 상기 KL 산출 단계(S100)를 통해서 각 클라이언트들은 이상적인 IID 분포(전역 기준 분포)와 자신의 로컬 데이터 분포 간의 KL 발산 값(D_{KL})을 산출하게 된다. 상기 KL 발산 값을 통해서 각 클라이언트의 로컬 데이터 분포가 이상적인 IID 분포와 얼마나 다른지를 판단할 수 있으며, 이는 하기의 수학식 1과 같이 정의할 수 있다.

【0037】**【수학식 1】**

$$D_{KL}(P_i \parallel Q) = \sum_{c=1}^{C} P_i(c) \log\left(\frac{P_i(c)}{Q(c)}\right)$$

【0038】(여기서, $P_i(c) = \frac{n_i(c)}{N_i}$ 는 로컬 데이터 분포로서, $n_i(c)$는 클래스 (c)에 속하는 샘플의 수이고, N_i 는 클라이언트(i) 내 학습 샘플의 총 개수이며,

【0039】 $Q(c) = \frac{1}{C}$ 는 이상적인 IID 분포로서, 모든 클라이언트가 동일한 로컬 클래스 분포를 가진다는 가정 하에 정의된다.)

【0040】상기의 수학식 1을 통해 상기 KL 산출 단계(S100)에서 각 클라이언트(i)는 자신의 KL 발산 값(D_{KL})을 산출하고, 이를 상기 서버에 전송하게 된다.

【0041】상기 정규화 단계(S200)는 상기 서버에서, 각 클라이언트들로부터 수신된 KL 발산 값(D_{KL})을 정규화하는 것이 바람직하다. 즉, 산출된 KL 발산 값(D_{KL})은 0과 1사이로 정규화되어 각 클라이언트의 이질성 수준을 나타내게 된다. KL 발산 값(D_{KL})이 작다는 것은 보다 이상적인 IID 분포에 가까운 데이터를 의미하여 보다 일반적인 특성이 요구됨을 나타내고, KL 발산 값(D_{KL})이 클수록 비-IID 데이터를 의미하며 더 강한 개인화가 필요함을 시사한다. 이 때, 상기 정규화 단계(S200)는 모든 클라이언트들로부터 상기 KL 산출 단계(S100)를 통해 산출된 KL 발산 값(D_{KL})을 수신받으며, 하기의 수학식 2를 통해 정규화하여 $KL_{norm}(i)$을 산출하게 된다.

【0042】**【수학식 2】**

$$KL_{norm}(i) = \frac{D_{KL}(P_i \| Q) - D_{KL}^{min}}{D_{KL}^{max} - D_{KL}^{min}}$$

【0043】이 때, 상기 KL 산출 단계(S100) 및 정규화 단계(S200)는 도 2의 step 1에 해당된다.

【0044】상기 성분 획득 단계(S300)는 상기 서버에서, 베이스 모델(W^0)의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 것이 바람직하다. 즉, 상기 가중치 행렬을 복수의 스펙트럼 성분으로 분해하여 획득하게 된다. 여기서, 스펙트럼 성분이란, 가중치 행렬의 변환 특성을 구성하는 복수의 성분을 의미하며, 각 성분은 해당하는 가중치 행렬에 대한 기여도에 따라 정렬될 수 있다.

【0045】상기 성분 획득 단계(S300)에 의한 특이값 분해는 하기의 수학식 3과 같은 형태로 표현될 수 있다.

【0046】**【수학식 3】**

$$W^0 = U\sqrt{\Sigma}V^T$$

【0047】(여기서, U는 베이스 모델의 가중치 행렬에 대한 특이값 분해를 수행하여 얻어지는 좌측 특이벡터 행렬을 의미하고,

【0048】V는 베이스 모델의 가중치 행렬에 대한 특이값 분해를 수행하여 얻어지는 우측 특이벡터 행렬을 의미하고,

【0049】Σ는 특이값을 대각 성분으로 포함하는 대각 행렬을 의미한다.)

【0050】상기 매핑 단계(S400)는 상기 서버에서, 상기 정규화 단계(S200)에 의해 정규화된 KL 발산 값($KL_{norm}(i)$)에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별 소정 범위의 특이 성분이 할당되도록 매핑하는 것이 바람직하다. 즉, 상기 스펙트럼 성분 중 클라이언트 별로 할당될 연속된 인덱스 구간을 결정하도록 구성된다. 이를 통해서, 유사한 데이터를 가지는 클라이언트는 주성분을 공유하고, 이질적인 데이터를 가지는 클라이언트는 마이너 성분을 적응하게 되어, 일반화와 개인화 간의 균형을 유지하게 된다.

【0051】상세하게는, 상기 서버에서, 상기 정규화 단계(S200)에 의해 정규화된 KL 발산 값($KL_{norm}(i)$)에 기초하여, 정규화된 KL 발산 값($KL_{norm}(i)$)을 하기의 수학식 4와 같이 SVD 스펙트럼의 시작/종료($Index_{start}(i)$/$Index_{end}(i)$)로 변환하게 되며, 해당하는 $Index_{start}(i)$부터 $Index_{end}(i)$까지의 구간이 곧 클라이언트 별 할당 범위(스펙트럼 슬라이스, 스펙트럼 부분 공간)에 해당된다.

【0052】**【수학식 4】**

$$Index_{start}(i) = [KL_{norm}(i) \times (R - r)],$$
$$Index_{end}(i) = Index_{start}(i) + r$$

【0053】(여기서, R은 베이스 모델의 가중치 행렬에 대한 특이값 분해를 수행하여 얻어지는 전체 특이값의 개수 또는, 사용 가능한 스펙트럼 성분의 최대 차원을 의미하고,

【0054】r은 각 클라이언트에 할당되는 저랭크 파라미터 집합의 랭크로서, 하나의 클라이언트가 선택하여 사용하는 스펙트럼 부분 공간의 크기를 의미한다.

【0055】즉, R은 전체 스펙트럼 범위를 나타내고, r은 전체 스펙트럼 중에서 클라이언트 별로 선택되는 부분 공간의 차원을 나타낸다.)

【0056】이 후, 상기 서버는 상기 할당 범위에 대응하는 스펙트럼 성분을 이용하여, 저랭크 파라미터 집합의 초기화를 수행하게 되며, 이는 하기의 수학식 5와 같이 정의된다.

【0057】**【수학식 5】**

$$A = U_r\sqrt{\Sigma_r},$$
$$B = \sqrt{\Sigma_r}V_r^T$$

【0058】(여기서, U는 베이스 모델의 가중치 행렬에 대한 특이값 분해를 수행하여 얻어지는 좌측 특이벡터 행렬을 의미하고,

【0059】V는 베이스 모델의 가중치 행렬에 대한 특이값 분해를 수행하여 얻어지는 우측 특이벡터 행렬을 의미하고,

【0060】Σ는 특이값을 대각 성분으로 포함하는 대각 행렬을 의미한다.)

【0061】이를 통해서, Index_start(i)와 Index_end(i)는 각각 클라이언트 i에 할당되는 스펙트럼 부분공간의 시작 인덱스 및 종료 인덱스를 의미하고, 상기 Index_start(i)부터 Index_end(i)까지의 인덱스 구간에 대응하는 U, Σ, V의 부분

행렬을 이용하여 해당 클라이언트에 대응하는 저랭크 파라미터 집합 A 및 B가 구성된다.

【0062】 즉, 상기의 수학식 5는 베이스 모델의 가중치 행렬의 SVD 스펙트럼 성분 중에서 클라이언트(i)에 할당된 부분 공간을 선택하고, 선택된 부분 공간을 기반으로 저랭크 파라미터 집합 A 및 B를 생성 또는 초기화하는 과정을 수식적으로 나타낸 것이다.

【0063】 상기 집합 구성 단계(S500)는 상기 서버에서, 상기 매핑 단계(S400)의 결과에 따라 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합(저랭크 어댑터)을 구성하고, 구성된 저랭크 파라미터 집합을 해당하는 클라이언트로 전송하는 것이 바람직하다.

【0064】 여기서, 상기 저랭크 파라미터 집합은 상기 베이스 모델의 파라미터를 변경하지 않고도 상기 베이스 모델의 출력 특성을 보정하기 위해 추가되는 학습 가능 파라미터들의 집합으로, 상기 서버는 각 클라이언트 별 데이터 이질성 수준에 따라 상이한 스펙트럼 성분이 반영되도록 상기 저랭크 파라미터 집합을 구성하게 된다.

【0065】 상기 성분 획득 단계(S300), 매핑 단계(S400) 및 집합 구성 단계(S500)는 도 2의 step 2에 해당된다.

【0066】 상기 로컬 학습 단계(S600)는 각 클라이언트에서, 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합만을 학습하고, 학습 결과인

학습된 저랭크 파라미터 집합을 상기 서버로 전송하는 것이 바람직하다. 이를 통해서, 훨씬 적은 수의 학습 파라미터로 효율적인 파인 튜닝을 수행하면서도 모델 정확도를 유지할 수 있게 된다.

【0067】 즉, 상기 로컬 학습 단계(S600)에서 각각의 클라이언트는 상기 집합 구성 단계(S500)에 의한 저랭크 파라미터 집합과 함께, 상기 저랭크 파라미터 집합이 기반하는 스펙트럼 성분의 할당 범위를 나타내는 인덱스 구간 정보(해당하는 $Index_{start}(i)$부터 $Index_{end}(i)$까지의 구간)를 전송받아, 상기 인덱스 구간 정보에 대응하는 부분 공간을 유지하면서 상기 저랭크 파라미터 집합의 학습 처리를 수행하게 된다.

【0068】 또한, 각 클라이언트는 로컬 학습 시, 상기 베이스 모델의 가중치 행렬을 갱신하지 않고, 상기 저랭크 파라미터 집합을 베이스 모델의 대응 레이어에 결합 또는 주입한 상태에서 로컬 데이터 셋에 대한 손실을 최소화하도록 상기 저랭크 파라미터 집합만을 갱신하게 된다.

【0069】 즉, 로컬 학습 동안 각 클라이언트의 레이어(l)에 대한 유효 가중치 ($W'_{\ell,i}$)는 하기의 수학식 6과 같이 표현된다.

【0070】 **【수학식 6】**

$$W'_{l,i} = W^{res}_{l,i} + \frac{\alpha}{r} A_{l,i} B^T_{l,i}$$

【0071】(여기서, $W_{l,i}^{res}$ 는 고정되는 베이스 모델의 가중치를 의미하며,

【0072】 $A_{l,i}$, $B_{l,i}$ 는 저랭크 파라미터 집합에 포함되는 학습 가능 파라미터를 의미하며,

【0073】 α는 스케일 계수이며,

【0074】 r은 저랭크 파라미터 집합의 랭크를 의미한다.)

【0075】 각 클라이언트는 로컬 데이터 셋에 대한 손실(L_i)를 감소시키도록 $A_{l,i}$, $B_{l,i}$ 만을 갱신하며, 그 과정은 하기의 수학식 7과 같이 정의할 수 있다.

【0076】 **【수학식 7】**

$$A_i^{(t+1)} = A_i^{(t)} - \eta \nabla_{A_i} \mathcal{L}_i, \quad B_i^{(t+1)} = B_i^{(t)} - \eta \nabla_{B_i} \mathcal{L}_i$$

【0077】(여기서, η은 학습률을 의미한다.)

【0078】 이 후, 상기 로컬 학습 단계(S600)는 로컬 학습이 완료되면, 갱신된 저랭크 파라미터 집합$\left(A_i^{(t)}, B_i^{(t)}\right)$을 상기 서버로 전송하게 된다.

【0079】 상기 배포 단계(S700)는 상기 서버에서, 상기 로컬 학습 단계(S600)에 의해 수신된 학습 결과를 집계하여, 다시 각 클라이언트로 재배포하는 것이 바람직하다.

【0080】 다시 말하자면, 상기 배포 단계(S700)는 상기 서버에서, 상기 로컬 학습 단계(S600)에 의해 수신된 학습 결과인 학습 처리된 저랭크 파라미터 집합

$(A_i^{(t)}, B_i^{(t)})$을 클라이언트 별 학습 데이터 수(N_i) 또는 미리 설정된 가중치에 기초한 가중 평균으로 집계하여, 상기 집계된 저랭크 파라미터 집합을 생성하여, 다시 각 클라이언트로 재배포하게 된다.

【0081】일 예를 들자면, 전체 학습 데이터 수(N)를 $\sum_{i=1}^{K} N_i$로 정의하고, 각 클라이언트의 학습 처리된 저랭크 파라미터 집합$(A_i^{(t)}, B_i^{(t)})$인 경우, 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)은 하기의 수학식 8을 통해 산출될 수 있다.

【0082】**【수학식 8】**

$$A_{\text{glob}}^{(t)} = \frac{1}{N}\sum_{i=1}^{K} N_i A_i^{(t)}, \qquad B_{\text{glob}}^{(t)} = \frac{1}{N}\sum_{i=1}^{K} N_i B_i^{(t)}$$

【0083】이 후, 상기 서버는 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)을 각각의 클라이언트로 재배포하게 된다.

【0084】이 후, 연합 학습 방법에 따라, 각각의 클라이언트는 다음 학습 라운드에 따른 상기 로컬 학습 단계(S600)를 수행하게 된다.

【0085】즉, 다음 학습 라운드에 따른 상기 로컬 학습 단계(S600)를 수행하기 위해, 각각의 클라이언트는 자신의 저랭크 파라미터 집합을 재배포된 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)으로 갱신한 후, 로컬 학습 처리를 반복하게 된다.

【0086】즉, 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법은 각 학습 라운드마다, 상기 로컬 학습 단계(S600) 및 배포 단계(S700)를 반복 수행하여, 집계된 저랭크 파라미터 집합을 최종 생성함으로써, 글로벌 모델의 적응을 달성하게 된다.

【0087】다시 말하자면, 본 발명은 베이스 모델의 파라미터를 전송하거나 갱신하지 않고도, 저랭크 파라미터 집합의 집계 및 재배포를 반복함으로써, 글로벌 모델(전역 모델)의 적응을 달성하게 된다.

【0088】상기 로컬 학습 단계(S600) 및 배포 단계(S700)는 도 2의 step 3에 해당된다.

【0089】더불어, 상술한 본 발명을 서버에서 수행하는 관점에서 기재하자면, 복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하고, 이를 정규화하는 단계, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 단계, 상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별로 소정 범위의 특이 성분이 할당되도록 매핑하는 단계, 상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하는 단계 및 상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는 단계를 포함하는 것이

바람직하다. 각 단계들의 세부 동작은 상술한 바와 같기 때문에, 자세한 설명은 생략한다.

【0090】본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템은 서버 및 복수의 클라이언트에 의해 수행된다. 각 구성의 동작에 대해서 자세히 알아보자면,

【0091】상기 서버는 각 클라이언트로부터 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 정규화하고, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여 스펙트럼 성분을 획득하며, 정규화된 KL 발산 값에 기초하여 상기 스펙트럼 성분 중 클라이언트 별 할당 범위를 결정하고, 상기 할당 범위에 기초하여 클라이언트 별 저랭크(low-rank) 파라미터 집합을 구성하여 해당 클라이언트로 전송하며, 각 클라이언트로부터 저랭크 파라미터 집합을 수신하여 집계한 후 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하고, 상기 복수의 클라이언트 각각은, 미리 설정된 기준 데이터 분포를 토대로 로컬 데이터 분포에 대한 KL 발산 값을 산출하여 상기 서버로 전송하고, 상기 서버로부터 전송된 저랭크 파라미터 집합을 수신하여 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합의 학습을 수행하며, 학습된 저랭크 파라미터 집합을 상기 서버로 전송하게 된다.

【0092】상세하게는, 각 클라이언트에서, 미리 설정된 기준 데이터 분포를 토대로, 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값(D_{KL})을 산출하게 된다. 이 때, 미리 설정된 기준 데이터 분포란, 이상적인

IID(Identically distributed) 데이터 분포를 의미하며, 상기 KL 산출 단계(S100)를 통해서 각 클라이언트들은 이상적인 IID 분포(전역 기준 분포)와 자신의 로컬 데이터 분포 간의 KL 발산 값(D_{KL})을 산출하게 된다. 상기 KL 발산 값을 통해서 각 클라이언트의 로컬 데이터 분포가 이상적인 IID 분포와 얼마나 다른지를 판단할 수 있으며, 이는 상의 수학식 1과 같이 정의할 수 있다.

【0093】 이 후, 각 클라이언트(i)는 자신의 KL 발산 값(D_{KL})을 산출하고, 이를 상기 서버에 전송하게 된다.

【0094】 상기 서버에서, 각 클라이언트들로부터 수신된 KL 발산 값(D_{KL})을 정규화하게 된다. 즉, 산출된 KL 발산 값(D_{KL})은 0과 1사이로 정규화되어 각 클라이언트의 이질성 수준을 나타내게 된다. KL 발산 값(D_{KL})이 작다는 것은 보다 이상적인 IID 분포에 가까운 데이터를 의미하여 보다 일반적인 특성이 요구됨을 나타내고, KL 발산 값(D_{KL})이 클수록 비-IID 데이터를 의미하며 더 강한 개인화가 필요함을 시사한다. 이 때, 상기 정규화 단계(S200)는 모든 클라이언트들로부터 상기 KL 산출 단계(S100)를 통해 산출된 KL 발산 값(D_{KL})을 수신받으며, 상기의 수학식 2를 통해 정규화하여 $KL_{norm}(i)$을 산출하게 된다.

【0095】 이 후, 상기 서버에서, 베이스 모델(W^0)의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하게 된다. 즉, 상기 가중치 행렬을 복수의 스펙트럼 성분으로 분해하여 획득하게 된다. 여기서, 스펙트럼 성분이란, 가중치 행렬의 변환 특성을 구성하는 복수의 성분을 의미하며, 각 성분은 해당하는 가중치 행렬에 대한 기여도에 따

라 정렬될 수 있다.

【0096】 이 후, 상기 서버에서, 정규화된 KL 발산 값($KL_{norm}(i)$)에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별 소정 범위의 특이 성분이 할당되도록 매핑하게 된다. 즉, 상기 스펙트럼 성분 중 클라이언트 별로 할당될 연속된 인덱스 구간을 결정하도록 구성된다. 이를 통해서, 유사한 데이터를 가지는 클라이언트는 주성분을 공유하고, 이질적인 데이터를 가지는 클라이언트는 마이너 성분을 적응하게 되어, 일반화와 개인화 간의 균형을 유지하게 된다.

【0097】 상세하게는, 상기 서버에서, 정규화된 KL 발산 값($KL_{norm}(i)$)에 기초하여, 정규화된 KL 발산 값($KL_{norm}(i)$)을 상기의 수학식 4와 같이 SVD 스펙트럼의 시작/종료($Index_{start}(i)$/$Index_{end}(i)$)로 변환하게 되며, 해당하는 $Index_{start}(i)$부터 $Index_{end}(i)$까지의 구간이 곧 클라이언트 별 할당 범위(스펙트럼 슬라이스, 스펙트럼 부분 공간)에 해당된다.

【0098】 이 후, 상기 서버는 상기 할당 범위에 대응하는 스펙트럼 성분을 이용하여, 저랭크 파라미터 집합의 초기화를 수행하게 되며, 이는 상기의 수학식 5와 같이 정의된다.

【0099】 이 후, 상기 서버에서, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합(저랭크 어댑터)을 구성하고, 구성된 저랭크 파라미터 집합을 해당하는 클라이언트로 전송하게 된다.

【0100】여기서, 상기 저랭크 파라미터 집합은 상기 베이스 모델의 파라미터를 변경하지 않고도 상기 베이스 모델의 출력 특성을 보정하기 위해 추가되는 학습 가능 파라미터들의 집합으로, 상기 서버는 각 클라이언트 별 데이터 이질성 수준에 따라 상이한 스펙트럼 성분이 반영되도록 상기 저랭크 파라미터 집합을 구성하게 된다.

【0101】이 후, 각 클라이언트에서, 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합만을 학습하고, 학습 결과인 학습된 저랭크 파라미터 집합을 상기 서버로 전송하게 된다.

【0102】즉, 각각의 클라이언트는 저랭크 파라미터 집합과 함께, 상기 저랭크 파라미터 집합이 기반하는 스펙트럼 성분의 할당 범위를 나타내는 인덱스 구간 정보(해당하는 $\mathrm{Index}_{\mathrm{start}}(i)$부터 $\mathrm{Index}_{\mathrm{end}}(i)$까지의 구간)를 전송받아, 상기 인덱스 구간 정보에 대응하는 부분 공간을 유지하면서 상기 저랭크 파라미터 집합의 학습 처리를 수행하게 된다.

【0103】또한, 각 클라이언트는 로컬 학습 시, 상기 베이스 모델의 가중치 행렬을 갱신하지 않고, 상기 저랭크 파라미터 집합을 베이스 모델의 대응 레이어에 결합 또는 주입한 상태에서 로컬 데이터 셋에 대한 손실을 최소화하도록 상기 저랭크 파라미터 집합만을 갱신하게 된다.

【0104】즉, 로컬 학습 동안 각 클라이언트의 레이어(l)에 대한 유효 가중치($W'_{\ell,i}$)는 상기의 수학식 6과 같이 표현된다.

【0105】이 후, 로컬 학습이 완료되면, 갱신된 저랭크 파라미터 집합 $(A_i^{(t)}, B_i^{(t)})$을 상기 서버로 전송하게 된다.

【0106】이 후, 상기 서버에서, 수신된 학습 결과를 집계하여, 다시 각 클라이언트로 재배포하게 된다. 다시 말하자면, 상기 서버에서, 수신된 학습 결과인 학습 처리된 저랭크 파라미터 집합$(A_i^{(t)}, B_i^{(t)})$을 클라이언트 별 학습 데이터 수(N_i) 또는 미리 설정된 가중치에 기초한 가중 평균으로 집계하여, 상기 집계된 저랭크 파라미터 집합을 생성하여, 다시 각 클라이언트로 재배포하게 된다.

【0107】일 예를 들자면, 전체 학습 데이터 수(N)를 $\sum_{i=1}^{K} N_i$로 정의하고, 각 클라이언트의 학습 처리된 저랭크 파라미터 집합$(A_i^{(t)}, B_i^{(t)})$인 경우, 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)은 상기의 수학식 8을 통해 산출될 수 있다.

【0108】이 후, 상기 서버는 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)을 각각의 클라이언트로 재배포하게 된다.

【0109】이 후, 연합 학습 방법에 따라, 각각의 클라이언트는 다음 학습 라운드에 따른 상기 로컬 학습을 수행하게 된다.

【0110】각각의 클라이언트는 자신의 저랭크 파라미터 집합을 재배포된 상기 집계된 저랭크 파라미터 집합($A_{glob}^{(t)}, B_{glob}^{(t)}$)으로 갱신한 후, 로컬 학습 처리를 반복하게 된다.

【0111】이를 통해서, 베이스 모델의 파라미터를 전송하거나 갱신하지 않고도, 저랭크 파라미터 집합의 집계 및 재배포를 반복함으로써, 글로벌 모델(전역 모델)의 적응을 달성하게 된다.

【0112】하기의 표 1은 상술한 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법에 대한 전체 수행 과정에 대한 수도 코드이다.

【0113】【표 1】

Algorithm 1 FedKLS: Federated KL-guided Low-rank Adaptation.

Input: Global full-parameter model $\mathcal{M}$, rank r, maximum rank R.
Output: Low-rank models $\mathcal{M}(A, B)$ personalized for each client i.
Client side:
for each client i **in parallel do**
  if round $t = 0$ **then** ▷ Initialization
    Compute the actual local distribution $P_i(c) = \frac{n_i(c)}{N_i}$.
    Compute the ideal IID distribution $Q(c) = \frac{1}{C}$.
    Compute KL divergence $D_{\mathrm{KL}}(P_i \parallel Q) = \sum_{c=1}^{C} P_i(c) \log(\frac{P_i(c)}{Q(c)})$.
    Each client i sends their KL divergence D_{KL} to the server.
  end if
  for round $t = 1, 2, \ldots, T$ **do** ▷ FL Training
    Receive the LoRA model from the server $\mathcal{M}(A, B)$ when $t = 1$, otherwise when $t > 1$, receive the aggregated adapters (A, B).
    Inject adapters: For each layer ℓ, inject adapters A, B during the forward pass.

$$W'_{\ell,i} \leftarrow W^{res}_{\ell,i} + \frac{\alpha}{r} A_{\ell,i} B^{\top}_{\ell,i}, \text{ where } W^{res}_{\ell,i} \text{ is frozen.}$$

    Local training: Update adapters using stochastic gradient descent:

$$A_i^{(t+1)} = A_i^{(t)} - \eta \nabla_A \mathcal{L}_i, \quad B_i^{(t+1)} = B_i^{(t)} - \eta \nabla_B \mathcal{L}_i.$$

    Send updated adapters $(A_i^{(t+1)}, B_i^{(t+1)})$ back to the server.
  end for
end for
Server side:
if round $t = 0$ **then** ▷ Initialization
  for each client i **in parallel do**
    Receive the KL Divergence $D_{\mathrm{KL}}(P_i \parallel Q)$ from all clients.
    Normalize: $KL_{\mathrm{norm}}(i) \leftarrow \frac{D_{\mathrm{KL}}(P_i \| Q) - D^{\min}_{\mathrm{KL}}}{D^{\max}_{\mathrm{KL}} - D^{\min}_{\mathrm{KL}}}$.
    Map to SVD index: $\mathrm{Index}_{\mathrm{start}}(i) \leftarrow \lfloor KL_{\mathrm{norm}}(i) \times (R - r) \rfloor$.
  end for
end if
for each communication round $t = 1, 2, \ldots, T$ **do** ▷ FL Aggregation
  Server aggregates $\{(A_i, B_i)\}_{i=1}^{K}$ into (A, B).
  Server sends aggregated (A, B) back to clients.
end for

【0114】더불어, 상술한 본 발명을 서버에서 수행하는 관점에서 기재하자면, 상기 서버는 프로세서 및 상기 프로세서에 의해 실행 가능한 명령어를 저장하는 메모리를 포함하고, 상기 프로세서는 복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 이를 정규

화하고, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하며, 상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별로 소정 범위의 특이 성분이 할당되도록 매핑하고, 상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하며, 상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는 것이 바람직하다. 또한, 상기 프로세서의 세부 동작은 상술한 바와 같기 때문에, 자세한 설명은 생략한다.

【0115】 이러한 본 발명의 일 실시예에 따른 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법은, 다양한 분야에서 활용 가능하다.

【0116】 일 예를 들자면, 헬스케어에 적용될 경우, 환자 데이터를 공유하지 않고도 병원, 연구소 및 연구기관 간에 의료 AI 모델을 협력 학습하는 데 이용될 수 있다. KL 발산 기반 개인화에 의해 각 병원은 자체 로컬 데이터 분포에 맞게 모델을 적응시킬 수 있어, 진단 정확도, 의료 영상 분석 및 개인 맞춤형 치료 계획의 성능을 향상시키면서 엄격한 데이터 프라이버시를 보장할 수 있다.

【0117】 또한, 금융 시스템에서는 은행, 보험사 및 규제 기관이 민감한 고객 데이터를 로컬에 유지한 채로 사기 탐지, 위험 예측 및 신용평가 모델을 협력 학습

할 수 있게 한다. 통신 효율적인 저랭크 적응을 통해 시스템 오버헤드를 줄이고 수렴을 가속하여, 보다 정확하고 강건한 금융 분석을 가능하게 한다.

【0118】 더불어, 스마트시티 및 IoT 분야에 적용될 경우, 감시 카메라, 센서 및 교통 제어 시스템과 같은 분산 IoT 기기들 간 연합학습을 향상시킬 수 있다. 로컬 데이터 이질성에 따라 모델을 적응시킴으로써, 실시간 이벤트 탐지, 예지 정비 및 자원 최적화에서의 성능을 개선하는 한편 네트워크 부하 및 에너지 소모를 최소화할 수 있다.

【0119】 또한, 모바일 및 엣지 컴퓨팅 분야에 적용될 경우, 휴대폰, 웨어러블 및 엣지 디바이스를 대상으로, 저대역폭 환경에서도 경량으로 모델을 미세조정하여 음성 비서, 추천 시스템 및 건강 모니터링 애플리케이션과 같은 AI 시스템을 개인화하는 것을 지원한다. 저랭크 구조에 의해 제한된 연산 자원 환경에서도 효율적인 동작이 가능하다.

【0120】 마지막으로, 통신 및 네트워크 최적화 분야에 적용될 경우, 통신 사업자는 네트워크 성능 모니터링, 트래픽 예측 및 서비스 최적화를 위한 적응형 모델 구축에 적용할 수 있다. 이질적인 네트워크 노드들로부터의 업데이트를 효율적으로 집계함으로써 통신 부담을 줄이고, 실시간 의사결정의 정확도를 향상시킬 수 있다.

【0121】 한편, 본 발명의 일 실시예에 의한 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법은 다양한 전자적으로 정보를 처리하는 수단을 통하여 수행될 수 있는 프로그램 명령 형태로 구현

되어 저장 매체에 기록될 수 있다. 저장 매체는 프로그램 명령, 데이터 파일, 데이터 구조 등을 단독으로 또는 조합하여 포함할 수 있다.

【0122】저장 매체에 기록되는 프로그램 명령은 본 발명을 위하여 특별히 설계되고 구성된 것들이거나 소프트웨어 분야 당업자에게 공지되어 사용 가능한 것일 수도 있다. 저장 매체의 예에는 하드 디스크, 플로피 디스크 및 자기 테이프와 같은 자기 매체(magnetic media), CD-ROM, DVD와 같은 광기록 매체(optical media), 플롭티컬 디스크(floptical disk)와 같은 자기-광 매체(magneto-optical media) 및 롬(ROM), 램(RAM), 플래시 메모리 등과 같은 프로그램 명령을 저장하고 수행하도록 특별히 구성된 하드웨어 장치가 포함된다. 프로그램 명령의 예에는 컴파일러에 의해 만들어지는 것과 같은 기계어 코드뿐만 아니라 인터프리터 등을 사용해서 전자적으로 정보를 처리하는 장치, 예를 들어, 컴퓨터에 의해서 실행될 수 있는 고급 언어 코드를 포함한다.

【0123】이상과 같이 본 발명에서는 구체적인 구성 소자 등과 같은 특정 사항들과 한정된 실시예 도면에 의해 설명되었으나 이는 본 발명의 보다 전반적인 이해를 돕기 위해서 제공된 것 일 뿐, 본 발명은 상기의 일 실시예에 한정되는 것이 아니며, 본 발명이 속하는 분야에서 통상의 지식을 가진 자라면 이러한 기재로부터 다양한 수정 및 변형이 가능하다.

【0124】따라서, 본 발명의 사상은 설명된 실시예에 국한되어 정해져서는 아니 되며, 후술하는 특허 청구 범위뿐 아니라 이 특허 청구 범위와 균등하거나 등가적 변형이 있는 모든 것들은 본 발명 사상의 범주에 속한다고 할 것이다.

【청구범위】

【청구항 1】

서버와 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법에 있어서,

각 클라이언트에서, 기설정된 기준 데이터 분포를 토대로, 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 산출하는 KL 산출 단계;

서버에서, 각 클라이언트들로부터 수신된 상기 KL 발산 값을 정규화하는 정규화 단계;

서버에서, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 성분 획득 단계;

서버에서, 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트 별 소정 범위의 특이 성분이 할당되도록 매핑하는 매핑 단계;

서버에서, 상기 매핑 단계의 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 구성된 저랭크 파라미터 집합을 해당하는 클라이언트로 전송하는 집합 구성 단계;

각 클라이언트에서, 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합을 학습하고, 학습 결과를 상기 서버로 전송하는 로컬 학습 단계; 및

서버에서, 상기 로컬 학습 단계에 의해 수신된 학습 결과를 집계하여, 다시

각 클라이언트로 재배포하는 배포 단계;

를 포함하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법.

【청구항 2】

제 1항에 있어서,

상기 배포 단계는

수신된 학습 결과인 학습 처리된 저랭크 파라미터 집합을 클라이언트 별 학습 데이터 수 또는 기설정된 가중치에 기초한 가중 평균으로 집계하여, 상기 집계된 저랭크 파라미터 집합을 생성하여, 다시 각 클라이언트로 재배포하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법.

【청구항 3】

제 1항에 있어서,

상기 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법은

각 학습 라운드마다, 상기 로컬 학습 단계 및 배포 단계를 반복 수행하여, 집계된 저랭크 파라미터 집합을 최종 생성하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법.

【청구항 4】

서버 및 복수의 클라이언트에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템에 있어서,

상기 서버는,

각 클라이언트로부터 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 정규화하고, 베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여 스펙트럼 성분을 획득하며, 정규화된 KL 발산 값에 기초하여 상기 스펙트럼 성분 중 클라이언트 별 할당 범위를 결정하고, 상기 할당 범위에 기초하여 클라이언트 별 저랭크(low-rank) 파라미터 집합을 구성하여 해당 클라이언트로 전송하며, 각 클라이언트로부터 저랭크 파라미터 집합을 수신하여 집계한 후 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하고,

상기 복수의 클라이언트 각각은,

기설정된 기준 데이터 분포를 토대로 로컬 데이터 분포에 대한 KL 발산 값을 산출하여 상기 서버로 전송하고, 상기 서버로부터 전송된 저랭크 파라미터 집합을 수신하여 상기 베이스 모델의 파라미터를 고정한 채 상기 저랭크 파라미터 집합의 학습을 수행하며, 학습된 저랭크 파라미터 집합을 상기 서버로 전송하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템.

【청구항 5】

제 4항에 있어서,

상기 서버는

수신된 저랭크 파라미터 집합을 클라이언트 별 학습 데이터 수 또는 기설정된 가중치에 기초한 가중 평균으로 집계하여 상기 집계된 저랭크 파라미터 집합을 생성하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템.

【청구항 6】

제 4항에 있어서,

상기 서버는

복수의 학습 라운드에 걸쳐 상기 저랭크 파라미터 집합의 수신, 집계 및 재배포를 반복 수행하여 집계된 저랭크 파라미터 집합을 갱신하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템.

【청구항 7】

서버에서 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법에 있어서,

복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하고, 이를 정규화하는 단계;

베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하는 단계;

상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트별로 소정 범위의 특이 성분이 할당되도록 매핑하는 단계;

상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하는 단계; 및

상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는 단계;

를 포함하는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 방법.

【청구항 8】

서버에 의해 수행되는 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템에 있어서,

프로세서; 및

상기 프로세서에 의해 실행 가능한 명령어를 저장하는 메모리;

를 포함하고,

상기 프로세서는

복수의 클라이언트로부터 각각 산출된 로컬 데이터 분포에 대한 KL 발산(Kullback-Leibler Divergence) 값을 수신하여 이를 정규화하고,

베이스 모델의 적어도 하나의 가중치 행렬에 대한 특이값 분해(SVD, Singular Value Decomposition)를 수행하여, 스펙트럼 성분을 획득하며,

상기 정규화된 KL 발산 값에 기초하여, 상기 스펙트럼 성분 중 클라이언트별로 소정 범위의 특이 성분이 할당되도록 매핑하고,

상기 매핑 결과에 따라, 결정된 클라이언트 별 할당 범위에 기초하여, 각 클라이언트 별로 저랭크(low-rank) 파라미터 집합을 구성하고, 이를 해당하는 클라이언트로 전송하며,

상기 클라이언트로부터 베이스 모델의 파라미터가 고정된 상태에서 학습된 저랭크 파라미터 집합을 수신하여 집계하고, 집계된 저랭크 파라미터 집합을 각 클라이언트로 재배포하는, 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템.

【요약서】

【요약】

본 발명은 자원 효율적인 대규모 사전 학습 모델 적응을 위한 KL 기반 저랭크 SVD 연합 학습 시스템 및 그 방법에 관한 것이다. 본 발명은 각 클라이언트가 자신의 로컬 데이터 특성에 따라 모델을 개인화하는 동시에, 다른 클라이언트와의 협업적 집계를 통해 이득을 얻을 수 있도록 연합 학습 환경에서 이질적인 클라이언트들 간에 효율적이고 개인화된 모델 적응을 수행하는 기술에 관한 것이다.

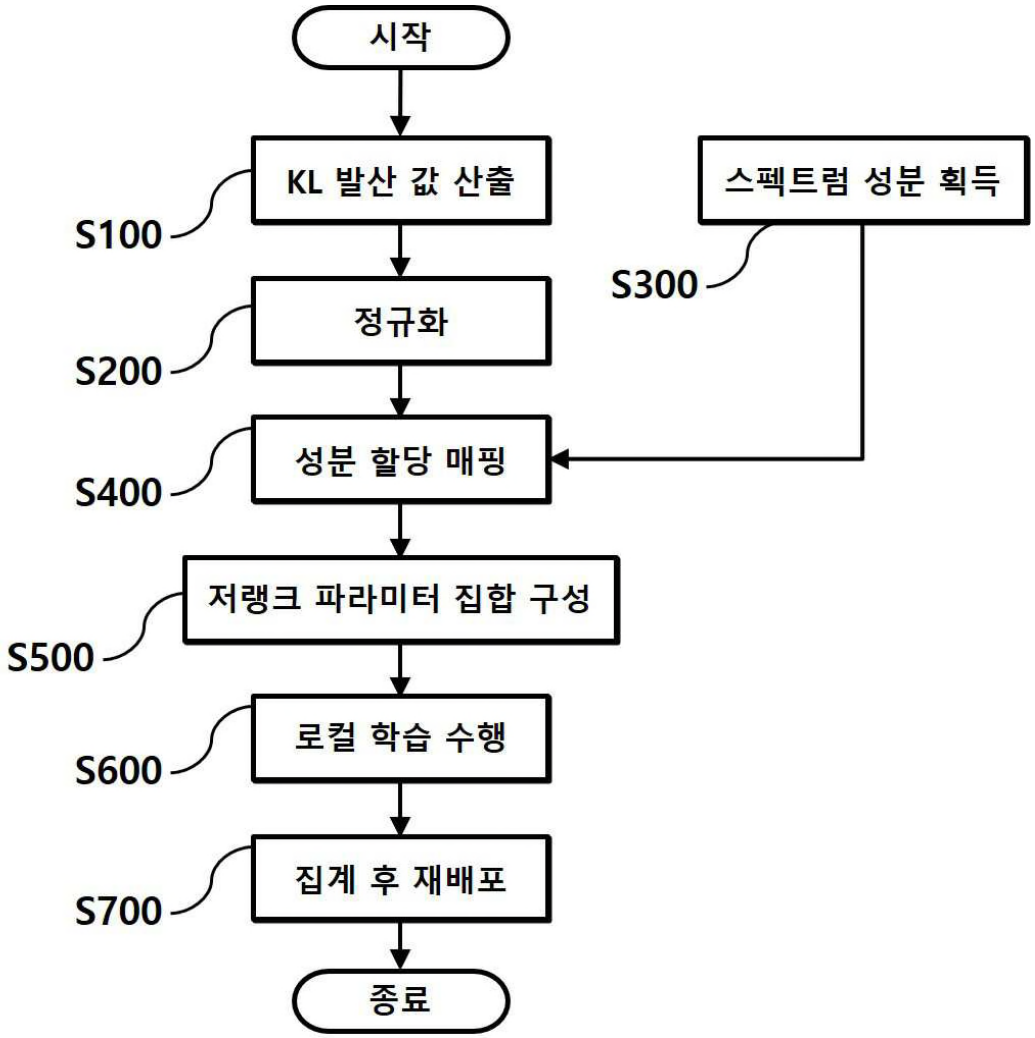
즉, 각 클라이언트의 데이터 이질성(heterogeneity)을 특정 모델의 부분 공간(subspace)과 동적으로 연계하여, 데이터 전송량을 크게 절감하는 동시에 전역 협업과 로컬 개인화 간의 균형을 달성하기 위한 기술에 관한 것이다.

【대표도】

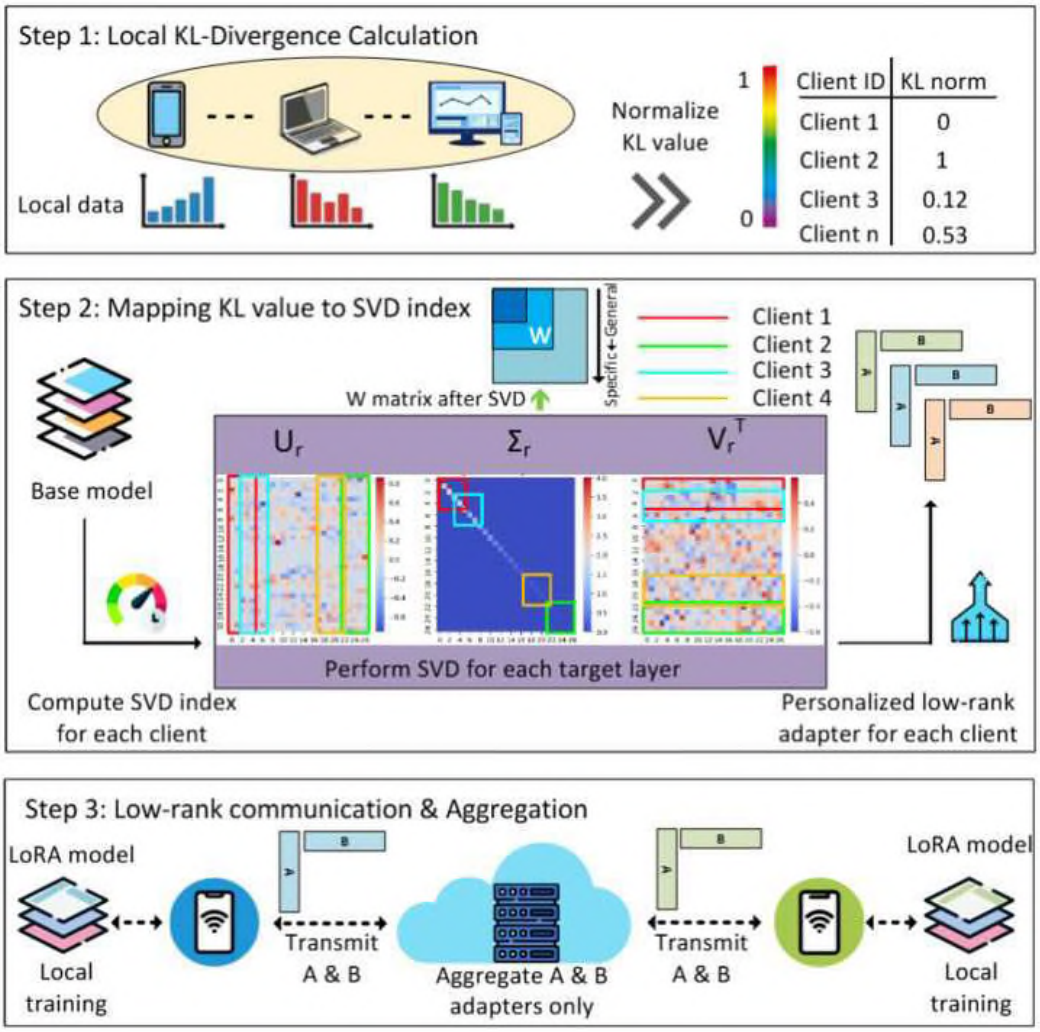
도 1

【도면】

【도 1】


시작
KL 발산 값 산출
S100
정규화
S200
스펙트럼 성분 획득
S300
성분 할당 매핑
S400
저랭크 파라미터 집합 구성
S500
로컬 학습 수행
S600
집계 후 재배포
S700
종료

【도 2】


Step 1: Local KL-Divergence Calculation
Local data
Normalize KL value
1
0
Client ID
KL norm
Client 1
0
Client 2
1
Client 3
0.12
Client n
0.53
Step 2: Mapping KL value to SVD index
W
W matrix after SVD
Specific ← General
Client 1
Client 2
Client 3
Client 4
Base model
U_r
Σ_r
V_r^T
Perform SVD for each target layer
Compute SVD index for each client
Personalized low-rank adapter for each client
Step 3: Low-rank communication & Aggregation
LoRA model
Local training
Transmit A & B
Aggregate A & B adapters only
Transmit A & B
LoRA model
Local training